

降维与度量学习

1. KNN 算法

给定测试样本，基于某种距离度量找出最近的 K 个样本
根据投票或平均输出结果

KNN 属于懒惰学习

训练：保存样本，收到样本后再处理。

相对的就有密切学习。

KNN 分类器泛化误差不

超过贝叶斯最优分类器两倍错误率

\Downarrow
要求足够的样本密度

1 维： 1000

2 维： 1000^2

没有足够的样本 \rightarrow 降维：通过某种数学变换 将原始高维属性 转化为低维子空间

2. MDS 算法

D : m 个样本的距離矩阵 $\begin{bmatrix} 11 & 12 \\ 12 & 22 \end{bmatrix}$

Z : 变化后的空间向量 $\|z_i - z_j\| = D_{ij}$

B : 降维后的内积矩阵 $D_{ij}^2 = B_{ii}^2 + 2B_{ij} + B_{jj}^2$

已知 $\sum_{i=1}^m b_{ii} = 0 \Rightarrow \sum_{i=1}^m b_{ij} = \sum_{j=1}^m b_{ij} = 0$, $\sum_{i=1}^m d_{ij}^2 = \text{tr}(B) + m b_{jj}$, $\sum_{j=1}^m d_{ij}^2 = \text{tr}(B) + m b_{ii}$, $\sum_{i=1}^m \sum_{j=1}^m d_{ij}^2 = 2m \text{tr}(B)$

$d_{ii}^2 = \frac{1}{m} \sum_{j=1}^m d_{ij}^2$, $d_{ij}^2 = \frac{1}{m} \sum_{i=1}^m d_{ij}^2$, $d_{..}^2 = \frac{1}{m^2} \sum_{i=1}^m \sum_{j=1}^m d_{ij}^2$

$b_{ij} = -\frac{1}{2} (d_{ij}^2 - d_{ii}^2 - d_{jj}^2 + d_{..}^2)$

即从 距离矩阵到 内积矩阵的计算。 $B = V \Lambda V^T$, $Z = \Lambda^{\frac{1}{2}} V^T \in \mathbb{R}^{d^* \times n}$.

步骤：1. 计算 d_{ii} , d_{ij} , $d_{..}$

2. 计算 内积矩阵 B

3. 对 B 作特征值分解

4. 取最大的 d^* 个特征值 Λ , 对应特征向量 V

样本坐标 = $V \Lambda^{\frac{1}{2}}$

3. 线性变换

$Z = W^T X$, $W \Rightarrow$ 变换矩阵

$$p(\text{err}) = 1 - \sum_{c \neq y} p(c|x) p(c|z)$$

其中 z 即最近邻样本

满足条件： x 附近任意小 δ

距离都有样本

$$\leq 1 - p^2 c^*(x) \quad C^*: \text{贝叶斯最优分类器结果}$$

$$= [1 + p(c^*(x))] [1 - p(c^*(x))] \quad 0 \leq p \leq 1$$

$$= 2 [1 - p(c^*(x))]$$

4. PCA

含盖的超平面：
 垂拟： 样本点到超平面距离足够近
 可分： 投影尽可能分开.

$$\text{重构 } \hat{x}_i = \sum_{j=1}^d z_{ij} w_j$$

$$\Rightarrow \begin{cases} \min_w -\text{tr}(w^T X X^T w) \\ \text{s.t. } w^T w = I. \end{cases}$$

$$X X^T w_i = \lambda_i w_i$$

1. 对样本中心化： $\tilde{x}_i \leftarrow x_i - \frac{1}{m} \sum_{i=1}^m x_i$

2. 计算协方差矩阵 $X X^T$ (最大化方差)

3. 对 $X X^T$ 作特征值分解

4. 取前 d' 个特征值对应特征向量 $w_1, \dots, w_{d'}$

$$z = w^T x$$

注： d' 如何选择

交叉验证

$$\frac{\frac{1}{d'} \lambda_1}{\sum_{i=1}^d \lambda_i} \geq t, \quad t \text{ 可以是 } 95\%$$

5. 核方法的引入

$$(\sum_{i=1}^m z_i z_i^T) w_j = \lambda_j w_j$$

$$\begin{aligned} w_j &= \sum_{i=1}^m z_i \frac{z_i^T w_j}{\lambda_j}, \quad \text{令 } \alpha_i^j = \frac{z_i^T w_j}{\lambda_j} \\ &= \sum_{i=1}^m z_i \alpha_i^j, \quad \text{另} z_i = \phi(x_i) \\ &= \sum_{i=1}^m \phi(x_i) \alpha_i^j \end{aligned}$$

$$\left(\sum_{i=1}^m \phi(x_i) \phi(x_i)^T \right) w_j = \lambda_j w_j$$

又有 $K(x_i, x_j) = \phi(x_i)^T \phi(x_j)$

$$K \sum_{i=1}^m \phi(x_i) \alpha_i^j = \lambda_j \sum_{i=1}^m \phi(x_i) \alpha_i^j$$

$$K \alpha^j = \lambda_j \alpha^j$$

得出 λ, α

$$\begin{aligned} z_j &= w^T \phi(x) = \sum_{i=1}^m \alpha_i^j \phi(x_i)^T \phi(x) \\ &= \sum_{i=1}^m \alpha_i^j K(x_i, x) \end{aligned}$$

b. 流形学习

在局部与全局空间同胚

测地线：计算本真距离，不能脱离曲面行走。

(1) ISOMAP：等度量映射

Solution：对于每个点基于欧氏距离寻找邻近点，邻近点相连到终点

利用 Dijkstra 或 Floyd 计算两点最短距离，输入 MDS 降维。

学习器
 输入：高维
 输出：低维

不太理解这里的笔路，断路。




图 10.6 三维空间中观察到的 3000 个样本点，是从本真二维空间中矩形区域采样后以 S 形曲面嵌入，此情形下线性降维会丢失低维结构。图中数据点的染色显示出低维空间的结构。




图 10.7 低维嵌入流形上的测地线距离(红色)不能用高维空间的直线距离计算，但能用近邻距离来近似

指定邻近点个数，
 正常阈值

(2) LLE: 局部线性嵌入，保留样本间的线性关系

$$\begin{aligned} \min_{w_1, w_2, \dots, w_n} & \sum_{i=1}^n \|x_i - \sum_{j \in Q_i} w_{ij} x_j\|_2^2 \\ \text{s.t. } & \sum_{j \in Q_i} w_{ij} = 1 \quad \Rightarrow \quad w_{ij} = \frac{\sum_{k \in Q_i} C_{jk}^{-1}}{\sum_{l \in Q_i} C_{lk}^{-1}} \quad \text{约束} \\ & C_{jk} = (x_k - x_j)^T C (x_k - x_j) \end{aligned}$$

$$\begin{aligned} \min_{z_1, z_2, \dots, z_n} & \sum_{i=1}^n \|z_i - \sum_{j \in Q_i} w_{ij} z_j\|_2^2 \\ \text{s.t. } & M = (I - W)^T (I - W) \quad \text{优化 } z \end{aligned}$$

$$\begin{aligned} \Rightarrow \min_z & \text{tr}(Z^T M Z) \\ \text{s.t. } & Z^T Z = I \end{aligned}$$

③ 对 M 作特征值分解，返回 最小的 d' 个特征值

$$z = \{z_1, z_2, \dots, z_n\}$$

7. 度量学习

目标：找到合适的低维空间性能优于原始空间

对应样本属性的距离度量

$$\begin{aligned} \text{加属性权重的 } d : \quad d^2(x_i, x_j) &= w_1 d_{ij,1}^2 + \dots + w_d d_{ij,d}^2 \\ &= (x_i - x_j)^T W (x_i - x_j) \\ \text{W通过学习确定, W为对角阵} & \quad \downarrow \quad (W)_{ii} = w_i \\ \text{扩展} \Rightarrow \text{属性相反} & \quad \downarrow \\ &= (x_i - x_j)^T M (x_i - x_j) \\ \text{M为半正定对称矩阵, } M &= P P^T \end{aligned}$$

NCA: 近邻成分分析

样本 x_i 对 x_j 分类结果的影响随距离增大而减小。

$$\begin{aligned} p_{ij} &= \frac{\exp(-\|x_i - x_j\|_M^2)}{\sum_l \exp(-\|x_i - x_l\|_M^2)} \\ \sum_i p_{ij} = \sum_j p_{ij} &\Rightarrow \max_p \quad \sum_{i=1}^n \sum_{j \in S_i} \frac{\exp(-\|p^T x_i - p^T x_j\|_2^2)}{\sum_l \exp(-\|p^T x_i - p^T x_l\|_2^2)} \end{aligned}$$

S_i : 与 x_i 同类的下标集

$$\begin{aligned} \min_M & \sum_{(x_i, x_j) \in M} \|x_i - x_j\|_M^2 \\ \text{s.t. } & \sum_{(x_i, x_j) \in C} \|x_i - x_j\|_M \geq 1 \\ & M \succeq 0 \end{aligned}$$

也可引入松弛，勿进

