

## 半监督学习

1. 主动学习：利用已标记样本训练模型，询问专家获取新样本加入训练

目的：更多的数据，更优的性能。

2. 半监督学习：让学习器不依赖外界交互，自动地利用未标记样本来提升学习性能。

聚类假设：同一簇的样本属于同一类别  
} → 相似样本，相似输出


高斯假设：数据分布在一个高斯轮廓上，邻近样本有相似的输出

先验监督：未标记样本不是预测数据

直推学习：未标记样本是预测数据

3. 生成式方法：基于EM算法的最大似然估计

假设：数据由同一隐含模型生成，未标记样本即模型的缺失参数。



不同模型假设会产生不同的方法

$$\text{假设样本由高斯混合模型生成: } p(x) = \sum_{i=1}^N \alpha_i \cdot p(x | \mu_i, \Sigma_i)$$

↓  
混合参数

$$\begin{aligned} \text{预测样本类别: } f(x) &= \underset{j \in \mathcal{Y}}{\operatorname{argmax}} p(y=j | x) = \underset{j \in \mathcal{Y}}{\operatorname{argmax}} \sum_{i=1}^N p(y=j, \theta=i | x) \\ &= \underset{j \in \mathcal{Y}}{\operatorname{argmax}} \sum_{i=1}^N p(y=j | \theta=i, x) \cdot p(\theta=i | x) \\ &\quad \downarrow \quad \text{表示样本 } x \text{ 由 } \theta_i \text{ 生成的概率.} \\ &= \frac{\sum_{i=1}^N \alpha_i \cdot p(x | \mu_i, \Sigma_i)}{\sum_{i=1}^N \alpha_i} \end{aligned}$$

$D_l \cup D_u$  标记与未标记的数据集为

$$\sum_{x_j, y_j \in D_l} \ln \left( \sum_{i=1}^N \alpha_i \cdot p(x_j | \mu_i, \Sigma_i) \cdot p(y_j | \theta=i, x_j) \right) \quad \text{② M步: 基于 } y_j \text{ 更新模型参数. } \{l\} \text{ 算; } \{u\} \text{ 有标记样本集.}$$

$$+ \sum_{x_j \in D_u} \ln \left( \sum_{i=1}^N \alpha_i \cdot p(x_j | \mu_i, \Sigma_i) \right)$$

③ E步: 计算未标记样本  $x_j$  属于各高斯成分的概率

$$y_{ji} = \frac{\alpha_i \cdot p(x_j | \mu_i, \Sigma_i)}{\sum_{k=1}^N \alpha_k \cdot p(x_j | \mu_k, \Sigma_k)}$$

$$\mu_i = \frac{1}{\sum_{j \in D_u} y_{ji} + l_i} \left( \sum_{j \in D_u} y_{ji} x_j + \sum_{x_j \in D_u \wedge y_j=i} x_j \right)$$

$$\Sigma_i = \frac{1}{\sum_{j \in D_u} y_{ji} + l_i} \left( \sum_{j \in D_u} y_{ji} (x_j - \mu_i)^T (x_j - \mu_i) \right)$$

$$+ \sum_{x_j \in D_u \wedge y_j=i} (x_j - \mu_i) (x_j - \mu_i)^T$$

$$\alpha_i = \frac{1}{n} \left( \sum_{j \in D_u} y_{ji} + l_i \right)$$

①, ② 循环, 迭代至收敛. 最后根据  $\alpha_i$  确定样本类别.

#### 4. 半监督 SVM

S3VM：考虑未标记样本，将两类样本分开，并穿过低密度区域

TSVM：对未标记样本进行标记操作，寻找所有样本间隔最大化的超平面。

```

输入：有标记样本集  $D_l = \{(x_1, y_1), (x_2, y_2), \dots, (x_l, y_l)\}$ ；  

       未标记样本集  $D_u = \{x_{l+1}, x_{l+2}, \dots, x_{l+u}\}$ ；  

       折中参数  $C_l, C_u$ 。  

过程：  

1: 用  $D_l$  训练一个 SVM；  

2: 用 SVMl 对  $D_u$  中样本进行预测，得到  $\hat{y} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$ ；  

3: 初始化  $C_u \ll C_l$ ；  

4: while  $C_u < C_l$  do  

5:   基于  $D_l, D_u, \hat{y}, C_l, C_u$  求解式(13.9)，得到  $(w, b), \xi$ ；  

6:   while  $\exists (i, j) | (\hat{y}_i \hat{y}_j < 0) \wedge (\xi_i > 0) \wedge (\xi_j > 0) \wedge (\xi_i + \xi_j > 2)$  do  

7:      $\hat{y}_i = -\hat{y}_i$ ；  

8:      $\hat{y}_j = -\hat{y}_j$ ；  

9:   基于  $D_l, D_u, \hat{y}, C_l, C_u$  重新求解式(13.9)，得到  $(w, b), \xi$   

10: end while  

11:  $C_u = \min\{2C_u, C_l\}$   

12: end while  

输出：未标记样本的预测结果： $\hat{y} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$ 

```

图 13.4 TSVM 算法

形式化地说，给定  $D_l = \{(x_1, y_1), (x_2, y_2), \dots, (x_l, y_l)\}$  和  $D_u = \{x_{l+1}, x_{l+2}, \dots, x_{l+u}\}$ ，其中  $y_i \in \{-1, +1\}$ ,  $l \ll u$ ,  $l+u = m$ . TSVM 的学习目标是为  $D_u$  中的样本给出预测标记  $\hat{y} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$ ,  $\hat{y}_i \in \{-1, +1\}$ ，使得

$$\begin{aligned} \min_{w, b, \hat{y}, \xi} \quad & \frac{1}{2} \|w\|_2^2 + C_l \sum_{i=1}^l \xi_i + C_u \sum_{i=l+1}^m \xi_i \\ \text{s.t.} \quad & y_i (w^T x_i + b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, l, \\ & \hat{y}_i (w^T x_i + b) \geq 1 - \xi_i, \quad i = l+1, l+2, \dots, m, \\ & \xi_i \geq 0, \quad i = 1, 2, \dots, m, \end{aligned} \quad (13.9)$$

其中， $(w, b)$  确定了一个划分超平面； $\xi$  为松弛向量， $\xi_i$  ( $i = 1, 2, \dots, l$ ) 对应于有标记样本， $\xi_i$  ( $i = l+1, l+2, \dots, m$ ) 对应于未标记样本； $C_l$  与  $C_u$  是由用户指定的用于平衡模型复杂度、有标记样本与未标记样本重要程度的折中参数。

思路：局部搜索。先利用已标记样本学习一个 SVM，对未标记样本进行标记，得到伪标记，代入右图，优化 SVM.

此时令  $C_u < C_l$  强化已标记样本的重要性，找出错误的伪标记，交换标记。在这个过程中逐步增加  $C_u$ ，直至

$C_u = C_l$  为止

- ① 对于类别不平衡： $C_u \rightarrow C_u^+, C_u^-$ ,  $C_u^+ = \frac{4C}{w^+} C_u^-$
- ② 对于未标记样本  $x_i, x_j$ ，伪标记  $\hat{y}_i, \hat{y}_j$  若  $\hat{y}_i + \hat{y}_j > 2$ ，交换标记。

5. 固半监督：样本为图中结点，相似度高的样本结点之间有边，在标记样本结点到未标记结点的扩散。

图  $C = (V, E)$  其中  $V = \{x_1, \dots, x_l, x_{l+1}, \dots, x_{l+u}\}$   
 $E$  表示为  $(W)_{ij} = \begin{cases} \exp(-\frac{\|x_i - x_j\|^2}{2\sigma^2}), & \text{if } i \neq j \\ 0, & \text{otherwise} \end{cases}$

即  $f: V \rightarrow \mathbb{R}$ .  $\begin{cases} y_i = \text{sign}(f(x_i)) \\ y_i \in \{-1, +1\} \end{cases} \rightarrow E(f) = \pm \sum_{i=1}^l \sum_{j=1}^l (W)_{ij} (f(x_i) - f(x_j))^2$   
 $= \sum_{i=1}^l d_i f^T C x_i - \sum_{i=1}^l \sum_{j=1}^l (W)_{ij} f(x_i) f(x_j)$

由  $E(f)$  有  $f(x_i) = y_i$  ( $i = 1, \dots, l$ )  
 $\nabla f = 0$ .

$$\Delta = D - W, \text{ 其中 } W \text{ 可写成 } \begin{bmatrix} W_{11} & W_{1u} \\ W_{u1} & W_{uu} \end{bmatrix}$$

$$D \text{ 可写成 } \begin{bmatrix} D_{11} & 0_{1u} \\ 0_{u1} & D_{uu} \end{bmatrix}$$

$$\begin{aligned} \nabla f = \left( \begin{bmatrix} f_1^T & f_u^T \end{bmatrix} \right) \left( \begin{bmatrix} D_{11} & 0_{1u} \\ 0_{u1} & D_{uu} \end{bmatrix} - \begin{bmatrix} W_{11} & W_{1u} \\ W_{u1} & W_{uu} \end{bmatrix} \right) \begin{bmatrix} f_1 \\ f_u \end{bmatrix} \\ = f_1^T (D_{11} - W_{11}) \cdot f_1 - 2 f_u^T W_{11} f_1 + f_u^T (D_{uu} - W_{uu}) f_u \end{aligned}$$

由  $\frac{\partial E(f)}{\partial f_u} = 0$  得  $f_u = (D_{uu} - W_{uu})^{-1} W_{11} f_1$  令  $P = D^{-1} w = \begin{bmatrix} D_{11}^{-1} & 0_{1u} \\ 0_{u1} & D_{uu}^{-1} \end{bmatrix} \begin{bmatrix} W_{11} & W_{1u} \\ W_{u1} & W_{uu} \end{bmatrix} = \begin{bmatrix} P_{11}^{-1} W_{11} & D_{11}^{-1} W_{1u} \\ D_{uu}^{-1} W_{u1} & P_{uu}^{-1} W_{uu} \end{bmatrix}$

$$f_u = (D_{uu} (I - D_{uu}^{-1} W_{uu}))^{-1} W_{11} f_1 = (I - D_{uu}^{-1} W_{uu})^{-1} D_{uu}^{-1} W_{11} f_1$$

$$= (I - P_{uu})^{-1} P_{11} f_1$$

二分差

多变量：定义一个  $(1+m) \times |Y|$  的非负矩阵  $F = (F_1^T, F_2^T, \dots, F_{m+1}^T)^T$

$F_i = ((F)_{i1}, (F)_{i2}, \dots, (F)_{i|Y|})$  为示例  $i$  的标记向量：初始化条件

另有  $y_i = \arg \max_{1 \leq j \leq |Y|} (F)_{ij}$ .

$$f(x) = (Y)_j = \begin{cases} 1, & \text{if } (1 \leq i \leq l) \wedge (y_i = j); \\ 0, & \text{otherwise.} \end{cases}$$

由  $F^*$  可得  $D_n$  中样本的标记  $(y_1, y_2, \dots, y_m)$ 。算法流程如图 13.5 所示。

其中  $\alpha \in (0, 1)$  为学习率， $\beta$  为松弛变量， $\gamma$  为惩罚项， $S(t)$  与初始化  $Y$  的重要性进行折中。基于式(13.19)迭代代替收敛表示为

$$F^* = \lim_{t \rightarrow \infty} F(t) = (1 - \alpha)F + \alpha S(t)^{-1}Y.$$

由  $F^*$  可获得  $D_n$  中样本的标记  $(y_1, y_2, \dots, y_m)$ 。算法流程如图 13.5 所示。

```
输入: 样本集 D = {(x_i, y_i), (x_{i+1}, y_{i+1}), ..., (x_n, y_n)};  
输出: 样本集 D_n = {(x_1, y_1), (x_2, y_2), ..., (x_m, y_m)};  
1. 初始化参数:  
    - 学习率 α;  
    - 松弛变量 β;  
    - 惩罚项 γ;  
    - 正则化参数 λ;  
2. 用式(13.19)迭代更新 F(t);  
3. for t = 1, 2, ..., T do  
4.     if F(t) = S(t)^{-1}Y then  
5.         break  
6.     end if  
7.     F(t+1) = αS(t)^{-1}Y + (1 - α)F(t);  
8.     for i = 1, 2, ..., n do  
9.         if y_i ≠ F(t+1)(x_i) then  
10.             min_y = min_{y' ∈ {0, 1}} ||F(t+1)(x_i) - y'||  
11.             end for  
12.             输出: 4 种不同类型的样本集  $\hat{g} = (0, 1, 0, 1, \dots, 0, 1)$   
13.         end if  
14.     end for  
15. end for  
16. 重复上述步骤
```

图 13.5 迭代收敛算法

事实上, 图 13.5 的算法对应于正则化模型

$$\min_p \frac{1}{2} \left( \sum_{i=1}^n (\mathbf{W}_0 y_i - \frac{1}{\sqrt{\lambda}} \mathbf{F}_i^T \mathbf{F}_i)^2 \right) + p \sum_{i=1}^l ||\mathbf{F}_i - \mathbf{Y}_i||^2. \quad (13.31)$$

## 6. 基于分层的方法：使用多个学习率的分歧。

特点：存储开销大，收敛需要格外调整。

## 协同训练

利用多范围的互斥性。

充分：每个范围重产生最佳学习率

条件建立：① 每个范围基于有标记样本调整分量

② 增强未标记、产生伪标记，提供给另

一方重置作新增标记。

置信度：  
朴素贝叶斯：后验概率

svm：间隔大小

```
输入: 有标记样本集 D = {(x_1^T, y_1), (x_2^T, y_2), ..., (x_n^T, y_n)};  
未标记样本集 D_u = {(x_{n+1}^T, x_{n+2}^T), ..., (x_{n+m}^T, x_{n+m}^T)};  
最小的步长大小 λ;  
每轮的正树数 p;  
每轮的反树数 n;  
基学习算子 L;  
学习次数 T.  
过程:  
1. 从 D_u 中随机抽取 s 个样本形成缓冲集 D_u';  
2.  $D_u' = D_u - D_u'$ ;  
3. for t = 1, 2, ..., T do  
4.      $D_t^0 = \{(x_i^T, y_i) \mid (x_i^T, y_i) \in D\}$ ;  
5.     end for  
6. for t = 1, 2, ..., T do  
7.     for i = 1, 2, ..., m do  
8.          $L(x_i^T)$ ;  
9.         分类 h_i 在  $D_t^0 = \{(x_i^T \mid (x_i^T, y_i) \in D_t^0\}$  上的分类置信度。  
10.        置信度最高的样本  $D_t^0 = D_t^0 \cup \{x_i^T\}$ , n 个反置信度最高的样本  $D_u' = D_u' \cup \{x_i^T\}$ ;  
11.        由  $D_t^0$  生成的标记比例  $D_t^{0,1} = \{(x_i^T, y_i+1) \mid x_i^T \in D_t^0\}$ ;  
12.        由  $D_u'$  生成的标记比例  $D_u'^1 = \{(x_i^T, y_i-1) \mid x_i^T \in D_u'\}$ ;  
13.         $D_t^0 = D_t^0 \setminus (D_t^0 \cap D_u')$ ;  
14.    end for  
15.    if  $h_1, h_2$  均未发生改变 then  
16.        break  
17.    else  
18.        for i = 1, 2 do  
19.             $D_t^i = D_t^0 \cup (D_t^{0,1} \cup D_u'^1)$ ;  
20.        end for  
21.    end if  
22. end for  
输出: 分类器  $h_1, h_2$ 
```

图 13.6 协同训练算法

## 7. 半监督聚类


第一类监督信息：聚类过程中保持从 C 与 C' 的约束

第二类监督信息：少量有标记样本，作种子，初始化

### 聚类中心

```
输入: 样本集 D = {x_1, x_2, ..., x_m};  
聚类中心数 k;  
勿扰约束集合 C;  
聚类簇数 k';  
过程:  
1. 从 D 中随机选取 s 个样本作为初始的向量  $(\mu_1, \mu_2, \dots, \mu_s)$ ;  
2. repeat  
3.     for r = 1, 2, ..., k' do  
4.         for i = 1, 2, ..., m do  
5.             计算样本  $x_i$  与各均值向量  $\mu_j$  ( $1 \leq j \leq k$ ) 的距离:  $d_{ij} = ||x_i - \mu_j||_2$ ;  
6.             K =  $\{j \mid d_{ij} = \min_{1 \leq j \leq k} d_{ij}\}$ ;  
7.             if r = 1 then  
8.                 is_merged = false;  
9.             while ~is_merged do  
10.                 for j = 1, 2, ..., k do  
11.                     if  $\exists i \in C$  使得  $i$  到  $\mu_j$  的距离最近的簇:  $r = \arg \min_{1 \leq j \leq k} d_{ij}$ ;  
12.                     if  $\mu_j$  不满足聚类约束  
13.                          $C_j = C_j \cup \{i\}$ ;  
14.                     else  
15.                          $K = K \setminus \{r\}$ ;  
16.                         if  $K = \emptyset$  then  
17.                             break  
18.                         end if  
19.                     end while  
20.                 end for  
21.             end for  
22.             for j = 1, 2, ..., k do  
23.                  $\mu_j = \frac{1}{|C_j|} \sum_{i \in C_j} x_i$ ;  
24.             end for  
25.         until 均值向量均未更新  
输出: 聚类划分  $\{C_1, C_2, \dots, C_k\}$ 
```

图 13.7 半监督聚类法



```
输入: 样本集 D = {x_1, x_2, ..., x_m};  
少量有标记样本 S =  $\bigcup_{j=1}^k S_j$ ;  
聚类簇数 k;  
过程:  
1: for j = 1, 2, ..., k do  
2:    $\mu_j = \frac{1}{|S_j|} \sum_{x \in S_j} x$   
3: end for  
4: repeat  
5:    $C_j = \{i \mid 1 \leq i \leq k\}$ ;  
6:   for j = 1, 2, ..., k do  
7:     for all  $x_i \in S_j$  do  
8:        $C_j = C_j \cup \{i\}$   
9:     end for  
10:   end for  
11:   for all  $x_i \in D \setminus S$  do  
12:     计算样本  $x_i$  与各均值向量  $\mu_j$  ( $1 \leq j \leq k$ ) 的距离:  $d_{ij} = ||x_i - \mu_j||_2$ ;  
13:     将样本  $x_i$  赋予最近的簇:  $r = \arg \min_{j=1,2,\dots,k} d_{ij}$ ;  
14:      $C_r = C_r \cup \{i\}$   
15:   end for  
16:   for j = 1, 2, ..., k do  
17:      $\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x$ ;  
18:   end for  
19: until 均值向量均未更新  
输出: 聚类划分  $\{C_1, C_2, \dots, C_k\}$ 
```

图 13.9 约束种子 k 均值法

